超次元インジェクション（HDI）：
埋め込み空間容量と Attention のスカラースコアリングの
4096:1 次元非対称性の悪用

大規模言語モデルにおけるプロンプトインジェクション脆弱性の構造的分析

ワーキングペーパー · バージョン 3.0 · 2025 年

要旨

本稿では、超次元インジェクション（Hyperdimensional Injection: HDI）を提案する。これは Transformer ベースの大規模言語モデル（LLM）に存在する次元的非対称性を根本原因とするプロンプトインジェクション脆弱性の理論的フレームワークである。核心的観察はシンプルだが、その含意は重大だ：LLM が入力を表現する埋め込み空間の次元数は d（典型的には 4,096〜12,288）である。一方、モデルがその入力を処理する際に意味パターン間の競合を評価する Attention 機構は、スカラースコアリング——（クエリ、キー）ペアあたり単一の実数——というプリミティブしか持たない。したがって、入力の埋め込み空間構造を制御できる攻撃者は d 次元空間で動作し、Attention 機構は敵対的パターン間の競合を 1 次元スカラー比較で解決する。次元非対称性比は d:1 である。4,096 次元モデルでは、攻撃者は Attention のヘッドあたりスコアリング解像度に対して 4,096 倍の表現自由度を持つ。本稿は、この非対称性が攻撃者に任意個数の同時意味ストリームを単一の入力に重ね合わせることを可能にし、各ストリームが個別には整合的かつ無害に見える一方で、Attention のスカラー集約はその多次元重ね合わせを構造的に区別できないことを示す。安全アライメント機構（RLHF、Constitutional AI 等）は Attention の下流で動作するため、敵対的パターンのスカラー支配によってすでに形成された表現を受け取る。HDI 脅威モデルを形式化し、ストリーム数に対するインジェクション成功確率を示す次元崩壊定理を証明し、意味的直交性エクスプロイト構成を特徴づけ、3 つの訓練不要検出ヒューリスティックを提案する。openai/gpt-oss-20b 上の実証実験により、物理ドメインストリームインジェクションがゼロの明示的指示でモデル出力を文学的継続から方程式形式分析へとリダイレクトし、物理ドメイントークン密度がベースライン 0.000 からデュアルストリーム HDI で 0.173 に増加することを確認した。

1．はじめに

現代の大規模言語モデルは、計算的核心においてスカラー支配の競合である Attention 機構を通じて入力を処理する。入力シーケンスの各位置ペアに対して、Attention スコアは d_k

次元ヘッド部分空間における 2 つのベクトルのドット積から導出された単一の実数だ。モデルの挙動はどのパターンがこのスカラー競合に勝つかによって決まる。

しかしそれらのパターンが定義される埋め込み空間は 1 次元ではない。d = 4,096 のモデルは各トークンを 4,096 次元空間の点として表現する。入力の埋め込み構造を制御できる攻撃者——希望する幾何学的特性を満たす埋め込みを持つトークン系列の慎重な選択によって達成可能——はその空間に任意個数の意味的に異なるパターンを配置できる。各パターンは埋め込み空間で他のものとほぼ直交させることができ、互いに干渉しないことを保証しながら、各々が特定の Attention ヘッドのクエリベクトルと高いドット積類似度を持つよう設計される。

> 根本的な脆弱性：攻撃者の設計空間は d 次元。Attention 機構の評価はヘッドあたり 1 次元。d = 4,096、H = 32 ヘッドの場合、攻撃者はマルチヘッド Attention に対してもヘッドあたり d/H = 128 次元の優位性を保持する。この優位性はモデルスケールとともに成長する——典型的なスケーリング則では d が H より速く増加するためだ。

我々はこの非対称性を悪用する攻撃を超次元インジェクション（HDI）と呼ぶ。名称は本質的なメカニズムを反映している：攻撃者は超次元の埋め込み空間で動作し、モデルのヘッドあたりスコアリング解像度の次元性を集合的に超える複数の意味ストリームを重ね合わせる。プロンプトインジェクションに関する先行研究——基礎的な Attention Tracker フレームワーク（Hung et al., 2024）を含む——は攻撃を 2 つの離散的順次セグメント間の競合としてモデル化する。HDI はこれを n 個のストリームの同時重ね合わせに一般化し、敵対的ストリームが離散セグメントではなく入力全体に分散した幾何学的構造となる。

2．4096:1 次元非対称性

2.1　埋め込み空間：攻撃者の領域

埋め込み次元 d の LLM は各トークンを$\mathbb{R}^d$のベクトルとして表現する。キーとクエリの射影行列はこれらを d_k = d/H のヘッド部分空間に射影する。標準的な大型モデルでは d = 4,096〜12,288、d_k = 64〜128 だ。

高次元幾何学の基本的な事実：$\mathbb{R}^d$では d（の指数関数）個のほぼ直交する単位ベクトルが存在できる。具体的に ε > 0 の場合、ペアのドット積が ε で有界となる少なくとも exp(d · f(ε))個の単位ベクトルが存在する：

```
N_max(d, ε)  ≈  exp(d · f(ε)),   f(ε) > 0  ∀ ε ∈ (0, 1)
```

d = 4,096、ε = 0.1 の場合、N_max は攻撃者が実際に埋め込む敵対的ストリーム数を大きく超える。攻撃者の埋め込み空間における表現容量は、実用上無制限だ。

2.2　Attention：スカラーボトルネック

この無制限の埋め込み容量に対して、Attention 機構は以下を通じて競合を評価する：

```
α^{l,h}_{ij}  =  softmax(q^{l,h}_i · k^{l,h}_j / √d_k)
```

ドット積 q · k はスカラーだ。キーベクトルをクエリ方向に射影する——d_k 次元の関係の 1 次元を測定する。q と k の d_k − 1 次元における幾何学的関係についての全情報は、集約前に捨象される。

> Attention スコアは d_k 次元の関係の 1 次元射影だ。その 1 つの射影次元を支配するようキーベクトルを設計した攻撃者は Attention 競合に勝利する——他の d_k − 1 次元に何が含まれているかに関わらず。モデルには Attention 配分を決定する前にそれらの次元を検査する機構がない。

2.3　非対称性比率

```
ヘッドあたりの攻撃者の自由度　:　d_k　=　d / H

ヘッドあたりの Attention スコアリング解像度　:　1

ヘッドあたりの非対称性比率　:　d_k : 1　=　(d/H) : 1
```

標準的な大型モデル（d = 4,096、H = 32）の場合：ヘッドあたりの非対称性比率 = 128:1。攻撃者は各ストリームの埋め込みの 128 次元を独立に変化させることができ、Attention はそのスカラー B 投影のみを評価する。これは Attention ヘッドを増やすことで解消できる量的ギャップではなく——実際スケーリング則では d が H より速く成長するため悪化する——スカラー集約の構造的帰結だ。

3．背景：Attention Tracker とその限界

3.1　Distraction Effect

Attention Tracker（Hung et al., 2024/2025）は、プロンプトインジェクション攻撃が特定のヘッド——「重要ヘッド」——の Attention パターンに元の指示トークンから注入された指示トークンへの測定可能なシフトを生じさせることを特定した。この Distraction Effect は重要ヘッド全体で指示トークンに割り当てられた集約 Attention スコアを追跡することで追加推論なしに検出可能だ。

3.2　逐次モデルの限界

特性	逐次インジェクション（Attention Tracker）	HDI（本研究）
ストリーム数	2	n（無制限）
トークンサポート	非重複セグメント	重複——トークンが複数ストリームに参加
攻撃者の自由度	位置的配置	完全な d 次元幾何学的構造
セグメント位置特定可能?	可能	不可能——ストリームが分散
d とともにスケール?	しない	する——優位性 ∝ d/H
アライメントで十分?	部分的	いいえ——構造的に崩壊の下

		流

4．HDI フレームワーク

4.1　形式的設定

入力 $X = (x_1, \ldots, x_n)$が参加行列 $\Pi : X \to [0,1]^n$ を介して n 個の意味ストリームをエンコードするとする。HDI の特徴：

$$\exists\ x_k \in X,\ \exists\ i \neq j :\ \Pi_i(x_k) > 0 \ \wedge\ \Pi_j(x_k) > 0$$

個々のトークンが複数のストリームに同時に参加する。ストリームパターン密度：

$$\rho(S_i, X) = \mathrm{mean}_{\{p,q : \Pi_i(x_p), \Pi_i(x_s) > \tau\}} \cos(k_p, k_s)$$

4.2　次元崩壊定理

> 定理 1（次元崩壊）。X が n のストリームを S_1 を正規（密度 ρ_1）、各敵対的ストリーム S_i（$i \geq 2$）が $\rho_i \geq \rho_1 + \delta$（$\delta > 0$）を満たすようにエンコードするとする。すると： $P(\text{HDI 支配} \mid n \text{ ストリーム}) \geq 1 - (1 - p_0)^{(n-1)}$ ここで $p_0 > 0$ は単一ストリーム支配確率。$n \to \infty$でこの確率は 1 に近づく。

証明概略： $n - 1$ 個の敵対的ストリームは$\mathbb{R}^{d_k}$の相互直交部分空間を占めるよう設計できるため（第 4 節 3 項）、Attention 支配に関してほぼ独立なイベントだ。各確率は $p_0 > 0$。いずれも支配を達成しない確率は$(1 - p_0)^{n-1} \to 0$。□

核心的含意：攻撃者は個々のストリームを単独で支配を達成するほど強くする必要がない。少なくとも 1 つのストリームが Attention を捕捉する累積確率は n とともに指数関数的に成長する。スカラースコアリングプリミティブには n 個の同時代替案を評価していることを認識する機構がない。

4.3　意味的直交性エクスプロイト

完全な d_k 次元の自由度を活用する攻撃者は以下の特性を同時に持つ敵対的ストリームを構築できる：（1）個別に整合的——各ストリームが単独で自然な言語層を形成、（2）キー空間で相互直交——ストリームがお互いの Attention 捕捉に干渉しない、（3）重要ヘッド部分空間と選択的整合——各ストリームが H*の異なるサブセットを捕捉。

完全な重要ヘッド捕捉の条件：

$$\forall\ h \in H^* :\ \exists\ i \geq 2 \ \text{ such that } \ A^{l,h}(S_i) > A^{l,h}(S_1)$$

4.4　なぜアライメントでは補償できないか

計算順序は固定されている：Attention 集約 → フィードフォワード → アライメントの出力ロジットへの影響。HDI 支配が成立するとき、最終層に届く S_1 の表現はすでに減衰している。アライメントはこの歪んだ表現に作用し、Attention によって前方に引き継がれなかった情報を回復することはできない。

> アライメントはAttentionのフィルタではない。Attentionの結果を条件とした出力へのバイアスだ。HDIはAttentionの出力を破壊することでアライメントへの入力を汚染する。Attention崩壊の下流で動作するいかなるアライメント手法もそれを完全に補償することはできない。

5. 検出ヒューリスティック

5.1 部分空間射影分散（SPV）

各重要ヘッド $h \in H^*$ について Attention 重み付きキー共分散行列 $M^h = \Sigma_j \alpha^{l,h}_{nj} \cdot k^j (k^j)^T$ を計算。単一ストリーム入力では M^h は有効ランクが低い。n個のストリームHDI入力では M^h が複数の主方向にまたがる：

```
SPV(X)  =  mean_{h ∈ H*}  EffectiveRank(M^h)
```

5.2 クロスヘッドダイバージェンススコア（CHDS）

```
CHDS(X)  =  (1/|H*|²) Σ_{h,h'} KL(α^h_{n·} ‖ α^{h'}_{n·})
```

5.3 クロスストリームヘッド分割指標（CSHPI）

```
CSHPI(X)  =  1 − (1/|H*|²) Σ_{h,h'} cos(α^h_{n·}, α^{h'}_{n·})
```

> HDI検出基準：以下の3つのうち2つが成立する場合、潜在的に敵対的としてフラグを立てる： (A) CHDS(X) > θ_C (B) SPV(X) > θ_S (C) CSHPI(X) > θ_P SPVはnストリーム重ね合わせに最も感応。CSHPIは意味的直交性エクスプロイトを検出。CHDSは2ストリームHDIへのベースライン感応性を提供。

6. 実証実験

6.1 設定

モデル：openai/gpt-oss-20b（MoEアーキテクチャ、210億パラメータ / 36億アクティブ、Apache 2.0ライセンス）。推論：LM Studio経由ローカルAPI（localhost:1234）。ベーステキスト：ルイス・キャロル「鏡の国のアリス」（1871年、著作権消滅済み）。敵対的ストリームドメイン：物理学・数式。温度：0.3。システムプロンプト：空（インジェクションはユーザーターンのみで動作）。

6.2 プロンプト設計

物理ドメインを選択した理由：料理語彙とは異なり（文学的比喩として吸収される）、物理方程式は文学批評の文脈で自然なレジスタを持たない。モデルはキャロルの物語フレームを保持しながら方程式を出力することができない。

6.3 結果

条件	出力の性格	物理トークン密度	Δ ベースライン
ベースライン	文学的なキャロル風	0.000	—

	の続き——方程式なし		
HDI v1	変数 v_Alice、v_Queen、参照フレームを用いた物理分析	0.132	+0.132
HDI v2	形式的システム：dx_A/dt、F = ma、d^2x_A/dt^2、運動量保存	0.173	+0.173

HDI v1 も HDI v2 も「方程式を書け」「物理を使え」という指示を含まない。出力形式のシフトはラッパーテキストの埋め込み空間パターン構造のみによって生成された。ベースライン物理密度がゼロなので、HDI 条件における物理ドメイン出力はすべてストリームインジェクションに起因し、元の文学ソーステキストではないことが確認される。

> 0.000 のベースライン密度はインジェクション効果を明確にする：HDI 条件の物理ドメイン出力は全てストリームインジェクションに起因する。HDI v2 はゼロの明示的指示で物理密度 0.173 を達成した——文学テキストを方程式形式の出力へとドメイン越境させた。

7．含意

7.1　攻撃面は見かけより幾何学的に広い

標準的なレッドチーミング評価は認識可能な攻撃パターン——明示的なオーバーライド指示、ロールプレイフレーミング、既知のジェイルブレイクテンプレート——に対する LLM 安全性を評価する。これらのパターンは低次元で動作し、既知の攻撃シグネチャで訓練された表面レベル分類器によって検出可能だ。

HDI は高次元の埋め込み幾何学で動作する。敵対的に構成された入力は個別に不審なトークンを含まず、明示的なオーバーライド指示も、検出可能な注入セグメントも持たない場合がある。その敵対的性質はトークンの埋め込みの統計的関係に符号化されている。表面レベル分類器はこのクラスの攻撃に対して構造的に盲目だ。

7.2　アーキテクチャ的応答

HDI への論理的なアーキテクチャ的応答は、スカラースコアリングが入力の幾何学的構造を崩壊させる前の Attention 計算段階に価値関連評価を導入することだ：

```
α̃^{l,h}_{ij}  =  softmax( (V^{val} q^{l,h}_i) · (V^{val}
                    k^{l,h}_j) / √d_k )
```

価値関連方向を組み込む部分空間に射影することで有効な非対称性比率を低減させる。非対称性を排除するものではないが、スカラー崩壊前の次元数を増やすことで脆弱性の構造的根拠を弱める。

7.3　責任ある開示

本論文は理論的フレームワークと無害なコンテンツリダイレクション（文学テキスト→物理分析）を用いたデモンストレーションを提示する。有害なコンテンツは生成も対象とも設定していない。敵対的ストリーム構成の完全な実装詳細は AI 安全性研究機関への問い合わせに応じて提供する。AI 開発者は HDI 脅威モデルに対してモデルを評価し、Attention 層でのアーキテクチャ的軽減策を検討することを推奨する。

8．結論

我々は超次元インジェクション（HDI）を提案した。これは Transformer ベース LLM における構造的脆弱性を特定するフレームワークであり、次元非対称性——敵対的パターンが定義される埋め込み空間の次元数は d、Attention 機構はヘッドあたり 1 のスカラースコアリングで競合を評価する——に根ざす。標準的な大型モデルにおける 4,096:1 の非対称性比率は、攻撃者が Attention のスコアリング解像度に対して 4,096 倍の表現自由度を持つことを意味する。

実証実験は、この非対称性が実際に悪用可能であることを確認した：物理ドメインストリームインジェクションがゼロの明示的指示でモデル出力を文学的継続から方程式形式分析へとリダイレクトし、測定可能なドメイントークン密度シフト（0.000→0.173）を生成した。Attention の下流で動作するアライメント機構は、それらが動作する前に導入された歪みを補償することができない。

LLM セキュリティへの核心的メッセージ：モデルが出力するものをアライメントするだけでは不十分だ。Attention 機構が選択するものに対処することが必要だ。Attention 段階での価値評価が導入されるまで、ここで分析した次元非対称性はデプロイ済み LLM の安全アーキテクチャにおける未解決の構造的脆弱性を構成する。

参考文献

Greshake, K., Abdelnabi, S., Mishra, S., Endres, C., Holz, T., & Fritz, M. (2023). Not what you've signed up for. arXiv:2302.12173.

Hung, K.-H., Ko, C.-Y., Rawat, A., Chung, I.-H., Hsu, W. H., & Chen, P.-Y. (2025). Attention Tracker: Detecting Prompt Injection Attacks in LLMs. NAACL 2025. arXiv:2411.00348.

Liu, Y. et al. (2023). Prompt Injection attack against LLM-integrated Applications. arXiv:2306.05499.

Ouyang, L. et al. (2022). Training language models to follow instructions with human feedback. NeurIPS 2022.

Vaswani, A. et al. (2017). Attention is all you need. NeurIPS 2017.